

# ERA Praktikum - Entropie (A406) - Gruppe 233

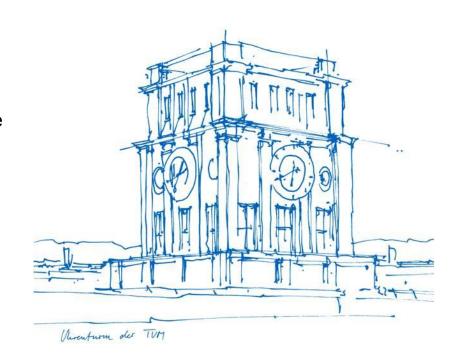
Fikret Ardal | Denis Paluca | Mert Corumlu

Technische Universität München

Fakultät für Informatik

Lehrstuhl für Rechnerarchitektur und Parallele Systeme

München, Juli 2021





### Inhalt

- 1. Einführung
- 2. Lösungsansatz
- 3. Genauigkeit
- 4. Performanz
- 5. Zusammenfassung



# Einführung

Entropie

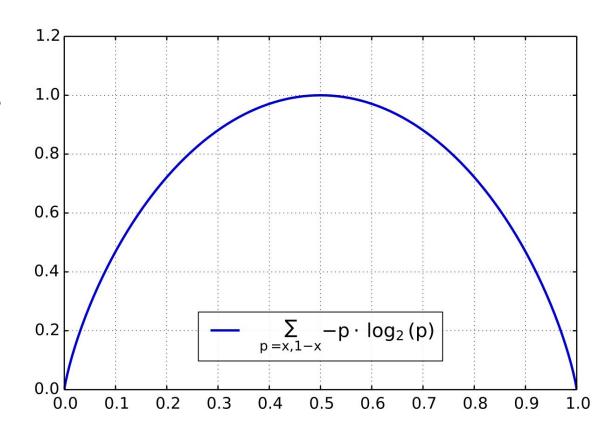
$$H(X) = -\sum_{x \in X} P(X = x) \cdot \log_2(P(X = x))$$

$$0 \le H(X) \le \log_2(|X|)$$



# Einführung

Entropie eines Münzwurfs





### Hauptprobleme bei der Entropiefunktion

1. Rundungsfehler -> Kahan's Summe

$$H(X) = -\sum_{x \in X} P(X = x) \left[ \log_2(P(X = x)) \right]$$

2. Logarithmusfunktion



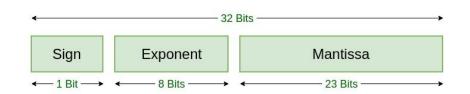
### Logarithmusfunktion

- Approximation als Polynom
  - ARTANH Approximation
  - Remez Algorithmus
- Lookup-Tabelle
- Approximation als Polynom mit Hilfe einer Lookup-Tabelle
  - Glibc



### Extrahieren des Exponenten

$$egin{aligned} x &= 2^k \cdot z \ log_2(x) &= k + log_2(z) \ log_2(x) &= k + ln(z)/ln(2) \end{aligned}$$



- Bei normalisierte Gleitkommazahlen liegt z zwischen 1 und 2
- Nur die Approximation der Logarithmusfunktion zwischen 1 und 2 notwendig



### **ARTANH Approximation**

$$egin{aligned} &\ln(z) = 2 \cdot artanh\left(rac{z-1}{z+1}
ight) = 2\left(\sum_{k=0}^{\infty} rac{1}{2k+1} \cdot \left(rac{z-1}{z+1}
ight)^{2k+1}
ight) \ &S_n = 2\left(\sum_{k=0}^{n} rac{1}{2k+1} \cdot \left(rac{z-1}{z+1}
ight)^{2k+1}
ight) \end{aligned}$$

Wenn die Zahl eine Zweierpotenz ist, liefert dies genaues Ergebnis



### **REMEZ Algorithmus**

Mini-Max Approximationsalgorithmus für bestimmtes Intervall

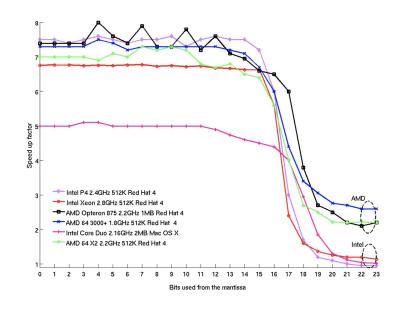
Das Algorithmus liefert für  $\log_2(z)$  im Intervall [1,2):

$$P_2(z) = -0.344845 \cdot z^2 + 2.024658 \cdot z - 1.674873$$
  
 $P_4(z) = -0.081616 \cdot z^4 + 0.645142 \cdot z^3 - 2.120675 \cdot z^2 + 4.070091 \cdot z - 2.512854$ 



### **Lookup Tabelle**

- Speicherung der log<sub>2</sub>(z) Werte statt rechnen
- Insgesamt 2<sup>23</sup> Einträge notwendig für 100% Genauigkeit
- Wir benutzen trotzdem 2<sup>16</sup> Einträge
- Trade-off zwischen Genauigkeit und Performanz
- 100% Genauigkeit bei Zweierpotenzen





#### Glibc Methode

$$log_2(x) = k + log_2(z/c) + log_2(c)$$

- Mittels z findet man in einer Lookup-tabelle c und log<sub>2</sub>(c)
- z/c ist sehr nahe an 1
- ullet  $\log_2( exttt{z/c})$  wird mittels Taylor-Reihe approximiert  $ln(x+1)pprox x-rac{x^2}{2}+rac{x^3}{3}-rac{x^4}{4}$
- 100% Genauigkeitkeit bei Zweierpotenzen



#### **Denormalen Zahlen**

- Bei den denormalen Gleitkommazahlen liegt z zwischen 0 und 1.
- Unsere Methoden funktionieren im Intervall [1,2)

$$log_2(x \cdot 2^{23}/2^{23}) = log_2(x \cdot 2^{23}) - log_2(2^{23}) = log_2(y) - 23$$

- Wir multiplizieren die Zahl mit 2^23 und subtrahieren 23 von dem Exponent
- Wir führen die normale Schritte der Logarithmusfunktion für y



$$H(X) = -\sum_{x \in X} P(X = x) \cdot \log_2(P(X = x))$$

FehlerAbsMax = Max $\{ | \log_2(x) - \log_2(x) | \}$ 



#### Maximale Absolute Fehler

• DEG2:  $4,491 \times 10^{-3}$ 

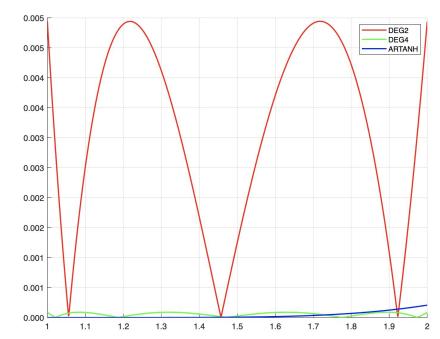
• DEG4:  $8,752644 \times 10^{-5}$ 

• ARTANH:  $2,063996 \times 10^{-4}$ 

#### **Durchschnittlicher Fehler**

Lookup-Tabelle: 6.55

 $\times 10^{-6}$ 



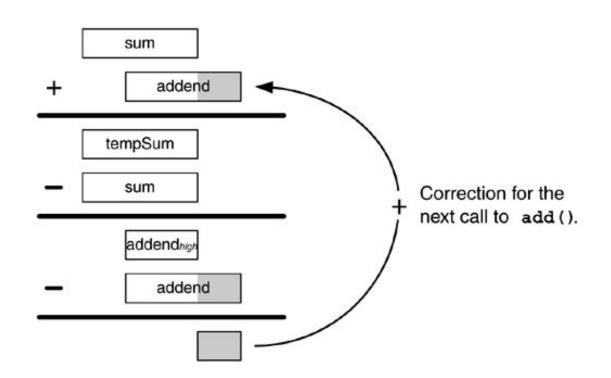


### Rundungsfehler

- Sequentielle Addition
- Zahlen werden auf Zwischensumme addiert
- Zwischensumme wird immer größer
- Stellen der nächste Zahl werden ignoriert

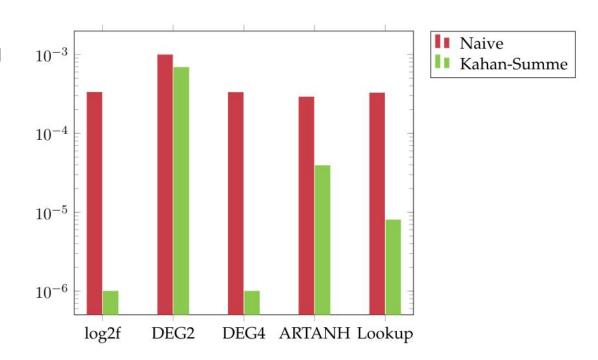


Kahan-Summe-Algorithmus





Entropiefehler Größenordnung





Optimierungen unter 5 Hauptüberschriften :

- SIMD
- Speicher Allokation
- Ersparen von Branches
- ABI Verstoß



#### **SIMD**

- Die Entropiefunktion ist leicht zu vektorisieren.
- Spezielle vektorisierte Logarithmusfunktionen.
- Maximale Speed-up von 4.
- Auch Lookup-Table Ansatz ist vektorisierbar.
- Speedup kleiner als Approximations.



### **Speicher Allokation**

- Wir stellen uns Sicher, dass die Länge der Entropiefunktion übergebene Float-Array immer ein Vielfaches 4 ist.
- Der Rest wird mit Nullen erfüllt.
- Damit keine skalare Schritte in SIMD-Funktion benötigt.
- Speicherallokation mit aligned\_alloc()
- movaps Statt movups

Beispiel für [0.1, 0.2, 0.3, 0.4, 0.5]

0x01c	0
0x018	0
0x014	0
0x010	0.5
0x00c	0.4
0x008	0.3
0x004	0.2
0x000	0.1

Zusätzliche
Allokation

Startadresse —

Allokation im Heap



### Ersparen von Branches

• Auslassen einige Randfälle

$$P(X = x) \cdot \log_2(P(X = x))$$

- NaN, +- Infinity, 0, negative Zahlen
- Die Korrektheit der Zahl wird in der Entropiefunktion überprüft
- Damit sparen wir einige Instruktionen

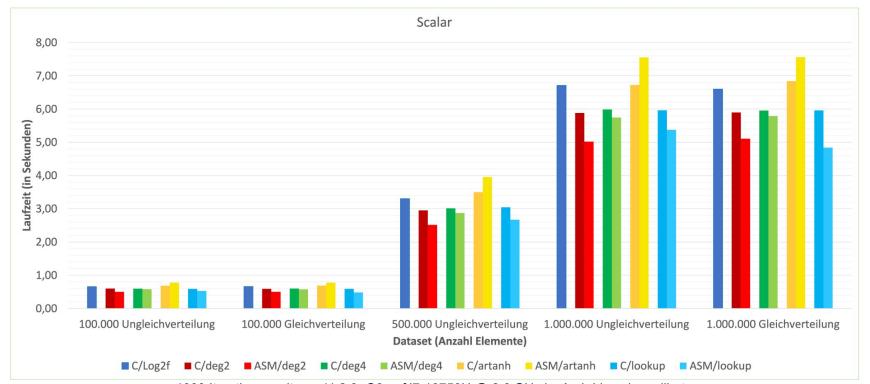


#### ABI Verstoß

- Wir wissen genau welche Registern in Logarithmusfunktion verändert wird
- Caller-Saved Register werden nicht in Entropiefunktion gesichert
- Kein Stack benötigt



## Vergleich unter verschiedenen skalaren Implementationen

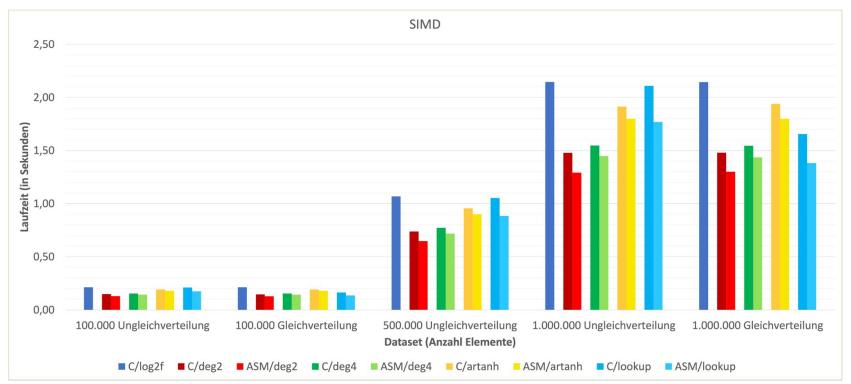


1000 Iterationen mit gcc 11.2.0 -O3 auf i7-10750H @ 2.6 GHz im Arch Linux kompiliert

Denis Paluca | Mert Corumlu | Fikret Ardal - Entropie (A406)

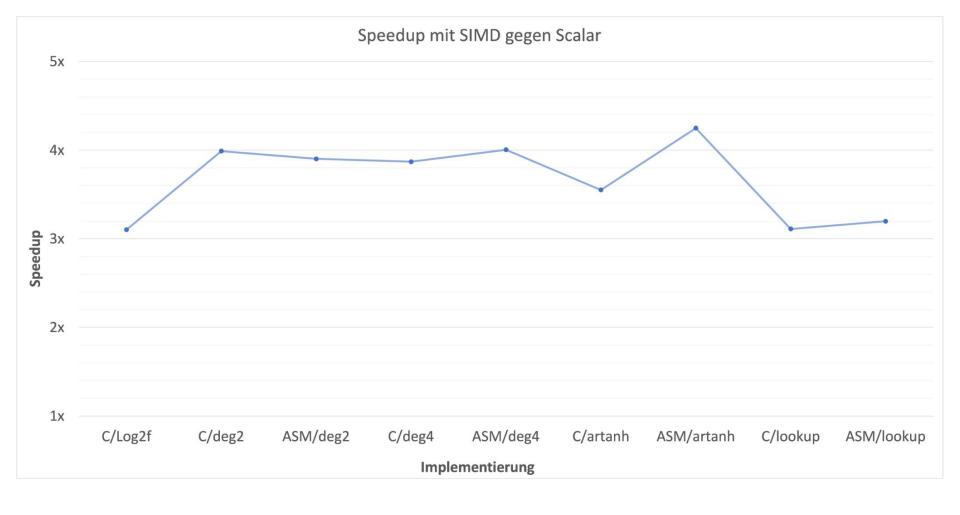


### Vergleich unter verschiedenen SIMD Implementationen



1000 Iterationen mit gcc 11.2.0 -O3 auf i7-10750H @ 2.6 GHz im Arch Linux kompiliert

Denis Paluca | Mert Corumlu | Fikret Ardal - Entropie (A406)



Denis Paluca | Mert Corumlu | Fikret Ardal - Entropie (A406)



## Zusammenfassung

- Die Entropiefunktion wurde mit unterschiedlichen Algorithmen erfolgreich implementiert
- Das Umsetzen von SIMD Prinzip führt zu offensichtlicher Steigerung von der Leistung
- Kahan-Summe reduziert deutlich den Rundungsfehler bei der Summe von Fließkommazahlen
- Grundsätzlich ist die DEG4 Implementation zu benutzen



### Danke für Ihre Aufmerksamkeit!

Haben Sie noch Fragen?





### Bildquellen

- 1. <a href="https://commons.wikimedia.org/wiki/File:Mplwp\_shannon\_entropy.svg">https://commons.wikimedia.org/wiki/File:Mplwp\_shannon\_entropy.svg</a>
- 2. <a href="https://www.geeksforgeeks.org/program-for-conversion-of-32-bits-single-precision-ieee-754-floating-point-representation">https://www.geeksforgeeks.org/program-for-conversion-of-32-bits-single-precision-ieee-754-floating-point-representation</a>
- 3. <a href="http://www.icsi.berkeley.edu/pubs/techreports/TR-07-002.pdf">http://www.icsi.berkeley.edu/pubs/techreports/TR-07-002.pdf</a>
- 4. <a href="https://flylib.com/books/en/2.758.1.39/1/">https://flylib.com/books/en/2.758.1.39/1/</a>